



Norges teknisk-naturvitenskapelige universitet
Institutt for matematiske fag

TMA4245 Statistikk

Vår 2015

Øving nummer 8, blokk II
Løsningsskisse

Oppgave 1

Betrakt et parallellsystem av to uavhengige komponenter, der levetiden til hver av komponentene er eksponensialfordelt med parameter λ , dvs

$$F_X(x) = 1 - e^{-\lambda x} \text{ for } x \geq 0.$$

Da komponentene danner et parallellsystem, vil systemet fungere dersom minst en av komponentene fungerer. Vi lar dermed levetiden til systemet betegnes ved $V = \max(X_1, X_2)$, og fordelingen til V finnes ved å benytte at komponenten med lengst levetid er mindre eller lik v hvis og bare hvis begge komponentene er mindre eller lik v :

$$F_V(v) = P(V \leq v) = P(\max(X_1, X_2) \leq v) = P(X_1 \leq v \cap X_2 \leq v)$$

$$\stackrel{Uavh.}{=} P(X_1 \leq v) \cdot P(X_2 \leq v) = (F_X(v))^2 = (1 - e^{-\lambda v})^2 = 1 - 2e^{-\lambda v} + e^{-2\lambda v}.$$

Vi har videre

$$f_V(v) = \frac{d}{dv} F_V(v) = 2\lambda e^{-\lambda v} - 2\lambda e^{-2\lambda v}.$$


Forventningen til V er gitt ved

$$E(V) = \int_{-\infty}^{\infty} v f_V(v) dv.$$

Ved delvis integrasjon får vi dermed

$$E(V) = \int_{-\infty}^{\infty} v f_V(v) dv = \int_0^{\infty} (2\lambda v e^{-\lambda v} - 2\lambda v e^{-2\lambda v}) dv = \frac{3}{2\lambda}.$$


Oppgave 2



Figur 1: Parallellkopling av to komponenter

Betrakt et seriesystem sammensatt av n uavhengige komponenter der levetiden til hver komponent følger en Weibull-fordeling med skalaparameter λ og formparameter α , gitt ved

$$F_X(x) = 1 - e^{-(\lambda x)^\alpha} \text{ for } x \geq 0.$$



Figur 2: Seriekopling av n komponenter

Da vi har et seriesystem, vil systemet fungere frem til første komponent svikter. Vi lar dermed levetiden til systemet betegnes ved $U = \min(X_1, X_2, \dots, X_n)$.

$$F_U(u) = P(U \leq u) = P(\min(X_1, X_2, \dots, X_n) \leq u) = 1 - P(\min(X_1, X_2, \dots, X_n) > u)$$

$$\begin{aligned} &= 1 - P(X_1 > u \cap X_2 > u \cap \dots \cap X_n > u) \stackrel{U_{avh.}}{=} 1 - \prod_{i=1}^n P(X_i > u) \\ &= 1 - (1 - F_X(u))^n = 1 - (1 - (1 - e^{-(\lambda x)^\alpha}))^n \\ &= 1 - (e^{-(\lambda x)^\alpha})^n = 1 - e^{-(n^{1/\alpha} \lambda x)^\alpha}. \end{aligned}$$

Dette er en Weibull-fordeling med skalaparameter $n^{1/\alpha}\lambda$ og formparameter α .


Oppgave 3

Scriptet `run_confds.m` simulerer n data x_1, \dots, x_n fra en normalfordeling med forventningsverdi $\mu = 1$ og varians $\sigma^2 = 2^2$ ved å trekke n ganger fra en standard normalfordeling $y_i \sim N(0, 1)$ og utføre lineærtransformasjonen

$$x_i = \mu + \sigma \cdot y_i, \quad i = 1, \dots, n$$

Fra uttrykket kan vi greit regne på at da vil $x_i \sim N(\mu, \sigma^2)$. (I Matlab trekker man fra en standard normalfordeling med funksjonen `'randn'`).


Kjører vi scriptet får vi et histogram av $n = 10000$ simulerte data x_1, \dots, x_n , som f.eks. kan se slik ut



Figur 3: Histogram av $n = 10000$ simulerte data fra $N(1, 2^2)$


Histogrammet til høyre er standardisert, altså transformert slik at areal under histogram-søylene blir 1. I plottet er det i grønt også tegnet inn kurven for normalfordelingen med forventning 1 og standardavvik 2. Vi ser at de simulerte dataene overlapper normalfordelingen de kommer fra veldig bra. Dette siden vi simulerer såpass mange datapunkter. Det resulterende gjennomsnittet $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = 1.0047$ er veldig nærme den sanne forventningsverdien som også ligger innenfor det estimerte konfidensintervallet $[0.96591, 1.0434]$.

Trekker vi stedet $n = 100000$ data (setter altså parameteren 'n' i scriptet til 100000) kan histogrammet f.eks. se ut som i Fig.2 med estimert forventningsverdi $\hat{\mu} = 0.9983$ og estimert 95% konfidensinterval $[0.9859, 1.0107]$. Igjen er estimatet tilnærmet likt sann forventningsverdi, som ligger innenfor konfidensintervallet, og overlappen mellom dataene og normalkurven er enda bedre.



Figur 4: Histogram av $n = 100000$ simulerte data fra $N(1, 2^2)$

Trekker vi $n = 1000$ data (setter altså parameteren 'n' i scriptet til 1000) kan histogrammet f.eks. se ut som i Fig.3. med estimert forventningsverdi $\hat{\mu} = 0.9594$ og estimert 95% konfidensinterval $[0.83741, 0.815]$. Estimatet er fortsatt bra, men ikke like nærme som i tilfellene med høyere n . Vi ser også at estimert konfidensinterval er litt bredere, og at overlappen mellom dataene og normalkurven er dårligere (dette er også fordi vi har så liten oppløsning på histogrammet).



Figur 5: Histogram av $n = 1000$ simulerte data fra $N(1, 2^2)$

Det estimerte konfidensintervallet er beregnet som

$$\left[\hat{\mu} - 1.96 \cdot \frac{\hat{\sigma}}{\sqrt{n}} , \hat{\mu} + 1.96 \cdot \frac{\hat{\sigma}}{\sqrt{n}} \right]$$

Når datamengden vokser og estimatet på standardavviket ikke varierer mye ser vi at faktoren $\frac{\hat{\sigma}}{\sqrt{n}}$ går mot 0, altså blir konfidensintervallet smalere jo større datamengden er. Vi merker oss også at vi her har brukt kvantilen $z_{0.025} = 1.96$ fra en normalfordeling selv om vi her bruker estimert varians. Med ukjent varians burde vi egentlig brukt kvantiler fra t -fordeling, men siden datamengden er så stor ($n \geq 1000$) vil t -fordeling med $n - 1$ frihetsgrader være tilnærmet lik standard normalfordeling.

Oppgave 4

a) Sannsynligheten for at et batteri virker etter 130 timer er

$$\begin{aligned} p = P(T > 130) &= 1 - P(\leq 130) = 1 - P\left(\frac{T - \mu}{\sigma} \leq \frac{130 - 117.2}{10}\right) \\ &= 1 - P(Z \leq 1.28) = 1 - 0.8997 = 0.1003 \end{aligned}$$

Vi har $n = 8$ slike batterier og de er uavhengig av hverandre. Hvis X er antall batterier som virker etter 130 timer, har vi at X består av n uavhengige forsøk, hver med sannsynlighet p for 'suksess', X er derfor binomisk fordelt. Radioen virker dersom minst 4 batterier:

$$\begin{aligned} P(\text{Radioen virker}) &= P(X \geq 4) = 1 - P(X \leq 3) \\ &= 1 - \sum_{x=0}^3 p(x; n=8, p=0.1) = 1 - 0.995 = \underline{\underline{0.005}} \end{aligned}$$

b)

$$\begin{aligned} M_X(t) &= E[e^{tX}] = \sum_{x=0}^n e^{tx} p(x; n, p) = \sum_{x=0}^n e^{tx} \binom{n}{x} p^x (1-p)^{n-x} \\ &= \sum_{x=0}^n \binom{n}{x} (pe^t)^x (1-p)^{n-x} = (pe^t + 1 - p)^n \end{aligned}$$

$$\begin{aligned} E[X] &= \left. \frac{dM_X(t)}{dt} \right|_{t=0} = n(pe^t + 1 - p)^{n-1} (pe^t) \Big|_{t=0} \\ &= n(p + 1 - p)^{n-1} p = \underline{\underline{np}} \end{aligned}$$

Oppgave 5

a) La V være målt vekt, slik at $V \sim N(\mu, \sigma^2) = N(10, 0.2^2)$. Vi får

$$\begin{aligned} P(V > 10.2) &= P\left(\frac{V - \mu}{\sigma} > \frac{10.2 - 10}{0.2}\right) = P(Z > 1) \\ &= 1 - P(Z \leq 1) = 1 - 0.8413 = \underline{\underline{0.1587}} \end{aligned}$$

$$\begin{aligned}
 P(|V - \mu| > 0.2) &= P(V - \mu > 0.2) + P(V - \mu < -0.2) \\
 &= P\left(\frac{V - \mu}{\sigma} > \frac{0.2}{0.2}\right) + P\left(\frac{V - \mu}{\sigma} < -\frac{0.2}{0.2}\right) \\
 &= P(Z > 1) + P(Z \leq -1) = 1 - P(Z \leq 1) + P(Z \leq -1) \\
 &= 2 \cdot P(Z \leq -1) = 2 \cdot 0.1587 = \underline{\underline{0.3174}}
 \end{aligned}$$

La $\bar{V} = \frac{1}{n} \sum_{i=1}^n V_i$, slik at $\bar{V} \sim N(\mu, \sigma^2/n)$. Vi får

$$\begin{aligned}
 P(|\bar{V} - \mu| > 0.2) &= P(\bar{V} - \mu > 0.2) + P(\bar{V} - \mu < -0.2) \\
 &= P\left(\frac{\bar{V} - \mu}{\sigma/\sqrt{n}} > \frac{0.2}{0.2/\sqrt{2}}\right) + P\left(\frac{\bar{V} - \mu}{\sigma/\sqrt{n}} < -\frac{0.2}{0.2/\sqrt{2}}\right) \\
 &= P(Z > \sqrt{2}) + P(Z \leq -\sqrt{2}) \\
 &= 1 - P(Z \leq \sqrt{2}) + P(Z \leq -\sqrt{2}) \\
 &= 2 \cdot P(Z \leq -1.41) = 2 \cdot 0.0793 = \underline{\underline{0.1586}}
 \end{aligned}$$

- b) Vi har $X_1 \sim N(\mu_A, \sigma^2)$ og $X_2 \sim N(\mu_B, \sigma^2)$ som er uavhengig av hverandre. Vi får ved fremgangsmåte 1:

$$\begin{aligned}
 E[\hat{\mu}_A] &= E[X_1] = \mu_A \\
 \text{Var}[\hat{\mu}_A] &= \text{Var}[X_1] = \sigma^2 \\
 E[\hat{\mu}_B] &= E[X_2] = \mu_B \\
 \text{Var}[\hat{\mu}_B] &= \text{Var}[X_2] = \sigma^2
 \end{aligned}$$

Vi har $Y_1 \sim N(\mu_A + \mu_B, \sigma^2)$ og $Y_2 \sim N(\mu_A - \mu_B, \sigma^2)$ som er uavhengig av hverandre. Vi får ved fremgangsmåte 2:

$$\begin{aligned}
 E[\tilde{\mu}_A] &= E[(Y_1 + Y_2)/2] = \frac{1}{2}(E[Y_1] + E[Y_2]) = \frac{1}{2}(\mu_A + \mu_B + \mu_A - \mu_B) = \mu_A \\
 \text{Var}[\tilde{\mu}_A] &= \text{Var}[(Y_1 + Y_2)/2] = \frac{1}{4}(\text{Var}[Y_1] + \text{Var}[Y_2]) = \frac{1}{4}(\sigma^2 + \sigma^2) = \sigma^2/2 \\
 E[\tilde{\mu}_B] &= E[(Y_1 - Y_2)/2] = \frac{1}{2}(E[Y_1] - E[Y_2]) = \frac{1}{2}(\mu_A + \mu_B - \mu_A + \mu_B) = \mu_B \\
 \text{Var}[\tilde{\mu}_B] &= \text{Var}[(Y_1 - Y_2)/2] = \frac{1}{4}(\text{Var}[Y_1] + \text{Var}[Y_2]) = \frac{1}{4}(\sigma^2 + \sigma^2) = \sigma^2/2
 \end{aligned}$$

Begge fremgangsmåtene gir forventningsrette estimatorer, så vi velger den med minst varians, dvs. fremgangsmåte 2: $\tilde{\mu}_A$ og $\tilde{\mu}_B$.

- c) Vi har $\tilde{\mu}_A = u_1(Y_1, Y_2) = (Y_1 + Y_2)/2$ og $\tilde{\mu}_B = u_2(Y_1, Y_2) = (Y_1 - Y_2)/2$, som gir oss at $Y_1 = w_1(\tilde{\mu}_A, \tilde{\mu}_B) = \tilde{\mu}_A + \tilde{\mu}_B$ og $Y_2 = w_2(\tilde{\mu}_A, \tilde{\mu}_B) = \tilde{\mu}_A - \tilde{\mu}_B$. Fra transformasjonsformelen for to variabler har vi da at

$$g_{\tilde{\mu}_A, \tilde{\mu}_B}(\tilde{\mu}_A, \tilde{\mu}_B) = f_{Y_1, Y_2}(w_1(\tilde{\mu}_A, \tilde{\mu}_B), w_2(\tilde{\mu}_A, \tilde{\mu}_B)) \cdot |J|$$

hvor

$$J = \begin{vmatrix} \delta w_1 / \delta \tilde{\mu}_A & \delta w_1 / \delta \tilde{\mu}_B \\ \delta w_2 / \delta \tilde{\mu}_A & \delta w_2 / \delta \tilde{\mu}_B \end{vmatrix} = \begin{vmatrix} 1 & 1 \\ 1 & -1 \end{vmatrix} = -2.$$

Siden Y_1 og Y_2 er uavhengige, har vi $f_{Y_1, Y_2}(y_1, y_2) = f_{Y_1}(y_1)f_{Y_2}(y_2)$ og vi får følgende:

$$\begin{aligned}
 g_{\tilde{\mu}_A, \tilde{\mu}_B}(\tilde{\mu}_A, \tilde{\mu}_B) &= f_{Y_1, Y_2}(w_1(\tilde{\mu}_A, \tilde{\mu}_B), w_2(\tilde{\mu}_A, \tilde{\mu}_B)) \cdot |J| \\
 &= f_{Y_1}(w_1(\tilde{\mu}_A, \tilde{\mu}_B)) f_{Y_2}(w_2(\tilde{\mu}_A, \tilde{\mu}_B)) \cdot |-2| \\
 &= \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma} \exp \left\{ -\frac{1}{2\sigma^2} (\tilde{\mu}_A + \tilde{\mu}_B - (\mu_A + \mu_B))^2 \right\} \\
 &\quad \cdot \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma} \exp \left\{ -\frac{1}{2\sigma^2} (\tilde{\mu}_A - \tilde{\mu}_B - (\mu_A - \mu_B))^2 \right\} \cdot 2 \\
 &= \left(\frac{1}{\sqrt{2\pi}} \frac{\sqrt{2}}{\sigma} \right)^2 \exp \left\{ -\frac{1}{2\sigma^2} [(\tilde{\mu}_A + \tilde{\mu}_B)^2 - 2((\tilde{\mu}_A + \tilde{\mu}_B) \right. \\
 &\quad \cdot (\mu_A + \mu_B) + (\mu_A + \mu_B)^2 + (\tilde{\mu}_A - \tilde{\mu}_B)^2 - 2(\tilde{\mu}_A - \tilde{\mu}_B) \\
 &\quad \cdot (\mu_A - \mu_B) + (\mu_A - \mu_B)^2] \} \\
 &= \left(\frac{1}{\sqrt{2\pi}} \frac{\sqrt{2}}{\sigma} \right)^2 \exp \left\{ -\frac{1}{2\sigma^2} [\tilde{\mu}_A^2 + 2\tilde{\mu}_A\tilde{\mu}_B + \tilde{\mu}_B^2 - 2\tilde{\mu}_A\mu_A \right. \\
 &\quad - 2\tilde{\mu}_A\mu_B - 2\tilde{\mu}_B\mu_B + \mu_A^2 + 2\mu_A\mu_B + \mu_B^2 + \tilde{\mu}_A^2 - 2\tilde{\mu}_A\tilde{\mu}_B \\
 &\quad + \tilde{\mu}_B^2 - 2\tilde{\mu}_A\mu_A + 2\tilde{\mu}_A\mu_B + 2\tilde{\mu}_B\mu_A - 2\tilde{\mu}_B\mu_B + \tilde{\mu}_A^2 \\
 &\quad \left. - 2\mu_A\mu_B + \mu_B^2] \right\} \\
 &= \left(\frac{1}{\sqrt{2\pi}} \frac{\sqrt{2}}{\sigma} \right)^2 \exp \left\{ -\frac{1}{2\sigma^2} [2\tilde{\mu}_A^2 + 2\tilde{\mu}_B^2 - 4\tilde{\mu}_A\mu_A - 4\tilde{\mu}_B\mu_B \right. \\
 &\quad \left. + 2\tilde{\mu}_A^2 + 2\tilde{\mu}_B^2] \right\} \\
 &= \left(\frac{1}{\sqrt{2\pi}} \frac{\sqrt{2}}{\sigma} \right)^2 \exp \left\{ -\frac{2}{2\sigma^2} [(\tilde{\mu}_A - \mu_A)^2 + (\tilde{\mu}_B - \mu_B)^2] \right\} \\
 &= \frac{1}{\sqrt{2\pi}} \frac{\sqrt{2}}{\sigma} \exp \left\{ -\frac{2}{2\sigma^2} (\tilde{\mu}_A - \mu_A)^2 \right\} \\
 &\quad \cdot \frac{1}{\sqrt{2\pi}} \frac{\sqrt{2}}{\sigma} \exp \left\{ -\frac{2}{2\sigma^2} (\tilde{\mu}_B - \mu_B)^2 \right\} \\
 &= g_{\tilde{\mu}_A}(\tilde{\mu}_A) g_{\tilde{\mu}_B}(\tilde{\mu}_B)
 \end{aligned}$$

og dermed er $\tilde{\mu}_A$ og $\tilde{\mu}_B$ uavhengige ($\tilde{\mu}_A \sim N(\mu_A, \sigma^2/2)$ og $\tilde{\mu}_B \sim N(\mu_B, \sigma^2/2)$).