



Norges teknisk-naturvitenskapelige universitet  
Institutt for matematiske fag

TMA4245 Statistikk  
Vår 2015

Øving nummer 11, blokk II  
Løsningsskisse

### Oppgave 1

- a) Merk fra Venn diagram at  $I$  ikke overlapper  $F$  eller  $R$ .

$$P(R|F) = \frac{P(R \cap F)}{P(F)} = \frac{0.3}{0.5} = 0.6$$

$$P(R|I') = \frac{P(R \cap I')}{P(I')} = \frac{P(R)}{1 - P(I)} = \frac{0.4}{1 - 0.05} = 0.421$$

- b) Generelle forutsetninger for binomisk fordeling
- i) Forsøksrekken består av  $n$  enkeltforsøk.
  - ii) Det registreres kun suksess eller ikke suksess.
  - iii) Sannsynligheten for suksess er lik i alle forsøk.
  - iv) Enkeltforsøkene er uavhengige.

For  $X$  har vi

- i) Det er valgt ut  $n$  kamper.
- ii) Vi registrerer kun om den som får første målet vinner(suksess) eller ikke.
- iii) Sannsynligheten for suksess er  $p$  og er antatt å være konstant.
- iv) Vi antar at kampene er uavhengige.

Dette er rimelige antakelser.

Sentralgrenseteoremet sier:

Dersom  $Z_1, Z_2, \dots, Z_n$  er uavhengig identisk fordelte fra sannsynlighetsfordelingen  $f_Z(z)$ , hvor  $E(Z) = \mu$  og  $Var(Z) = \sigma^2$ , så vil  $\sqrt{n} \frac{\bar{Z} - \mu}{\sigma}$  konvergere mot en normalfordeling med forventning 0 og varians 1. Der  $\bar{Z} = \frac{1}{n} \sum_{i=1}^n Z_i$ .

For en binomisk forsøksrekke, definer  $Z_i$  slik at:  $Z_i = 1$  hvis suksess, og  $Z_i = 0$  ellers. Med andre ord:

$$P(Z_i = z) = \begin{cases} p & \text{hvis } z = 1 \\ 1 - p & \text{hvis } z = 0 \end{cases}$$

Slik at  $E(Z_i) = p$  og  $Var(Z_i) = p(1 - p)$ .

Siden enkeltforsøkene er uavhengige så er  $Z_i$  ene også uavhengige. Av sentralgrenseteoremet følger at  $\sqrt{n} \frac{\hat{p}-p}{\sqrt{p(1-p)}}$  konvergerer mot en normalfordeling med forventning 0 og varians 1. Der  $\hat{p} = \frac{1}{n} \sum_{i=1}^n Z_i$ .

- c)  $H_0: p \geq 0.8$  mot  $H_1: p < 0.8$   
Eventuelt:  $H_0: p = 0.8$  mot  $H_1: p < 0.8$

Vi ønsker å forkaste dersom  $\hat{p} < k$ , hvor  $k$  bestemmes slik at

$$P(\hat{p} < k) = \alpha = 0.05$$

Vi benytter at  $Z = \sqrt{n} \frac{\hat{p}-p_0}{\sqrt{p_0(1-p_0)}}$  er tilnærmet normalfordelt med forventning 0 og varians 1 under  $H_0$ . Da har vi fra ligningen over:

$$P(Z < \frac{\sqrt{n}(k-p_0)}{\sqrt{p_0(1-p_0)}}) = 0.05$$

$$\frac{\sqrt{n}(k-p_0)}{\sqrt{p_0(1-p_0)}} = -Z_{0.05}$$

Dette gir  $k = p_0 - Z_{0.05} \sqrt{\frac{p_0(1-p_0)}{n}}$ . Vi forkaster  $H_0$  dersom:

$$\hat{p} < p_0 - Z_{0.05} \sqrt{\frac{p_0(1-p_0)}{n}} = 0.8 - 0.658 \frac{1}{\sqrt{n}}$$

For  $n = 24$  og  $X = \sum_{i=1}^n Z_i = 17$  får vi  $\hat{p} = 0.71$ ,  $k = 0.67$ . Vi forkaster ikke  $H_0$ .

Vi kan ikke påstå at ekspertkommentatoren tar feil på 5 prosent nivå.

- d) Vi ønsker at styrken på testen i alternativet  $p = 0.7$  skal være minst 0.9. Dvs

$$P(\hat{p} < 0.8 - 0.658 \frac{1}{\sqrt{n}} | p = 0.7) = 0.9$$

Vi benytter at  $Z = \sqrt{n} \frac{\hat{p}-0.7}{\sqrt{0.7 \cdot 0.3}}$  er tilnærmet normalfordelt med forventning 0 og varians 1 under alternativet med  $p = 0.7$ . Innsatt i kravet fra ligningen over gir dette:

$$P(Z < \sqrt{n} \frac{0.8-0.7}{\sqrt{0.7 \cdot 0.3}} - \frac{0.658}{\sqrt{0.7 \cdot 0.3}}) = 0.9$$

0.1 percentilen i normalfordelingen er lik  $Z_{0.1} = 1.28$ . Kravet som  $n$  må oppfylle blir dermed:

$$\sqrt{n} \frac{0.1}{\sqrt{0.7 \cdot 0.3}} - \frac{0.658}{\sqrt{0.7 \cdot 0.3}} = 1.28$$

Løsningen blir  $n = 155.1$  kamper. Dvs at vi må se minst 156 kamper for å oppnå den ønskede styrken på testen.

## Oppgave 2

- a) For at  $X$  skal være tilnærmet binomisk fordelt må en ha at  $N \gg n$  slik at det ikke betyr noe at samme person ikke vil bli spurt mer enn en gang.

$$P(X = 9) = \binom{n}{9} \theta^9 (1 - \theta)^{n-9} = \binom{20}{9} 0.5^9 (1 - 0.5)^{20-9} = \underline{\underline{0.1602}}$$

$$P(X > 9) = 1 - P(X \leq 9) \stackrel{\text{tabell}}{=} 1 - 0.412 = \underline{\underline{0.588}}$$

$$\begin{aligned} P(X > 9 | X \leq 12) &= \frac{P(X > 9 \cap X \leq 12)}{P(X \leq 12)} = \frac{P(10 \leq X \leq 12)}{P(X \leq 12)} \\ &= \frac{P(X \leq 12) - P(X \leq 9)}{P(X \leq 12)} \stackrel{\text{tabell}}{=} \frac{0.868 - 0.412}{0.868} = \underline{\underline{0.525}} \end{aligned}$$

- b)  $X \sim b(x; n, \theta)$

$$L(\theta) = P(X = x) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}$$

$$l(\theta) = \ln \binom{n}{x} + x \ln \theta + (n - x) \ln(1 - \theta)$$

$$l'(\theta) = x \frac{1}{\theta} + (n - x) \frac{1}{1 - \theta} (-1) = \frac{x}{\theta} - \frac{n - x}{1 - \theta}$$

$$l'(\theta) = 0$$

$$\Downarrow$$

$$\frac{x}{\theta} = \frac{n - x}{1 - \theta}$$

$$x(1 - \theta) = \theta(n - x)$$

$$x - x\theta = \theta n - \theta x$$

$$\theta = \frac{x}{n}$$

dvs. SME er  $\underline{\underline{\hat{\theta} = \frac{X}{n}}}$

$$E(\hat{\theta}) = E\left(\frac{X}{n}\right) = \frac{1}{n} E(X) = \frac{1}{n} n\theta = \underline{\underline{\theta}}$$

$$\text{Var}(\hat{\theta}) = \text{Var}\left(\frac{X}{n}\right) = \frac{1}{n^2} \text{Var}(X) = \frac{1}{n^2} n\theta(1 - \theta) = \underline{\underline{\frac{\theta(1 - \theta)}{n}}}$$

- c)  $H_0 : \theta = \frac{1}{2}$  mot  $H_1 : \theta \neq \frac{1}{2}$

Benytter testobservator

$$Z = \frac{X - n\frac{1}{2}}{\sqrt{n\frac{1}{2}(1 - \frac{1}{2})}} \approx N(z; 0, 1)$$

når  $H_0$  er riktig.

Dvs. forkaster  $H_0$  dersom

$$\begin{array}{ccc} Z < -z_{\frac{\alpha}{2}} & \text{eller} & Z > z_{\frac{\alpha}{2}} \\ & \Downarrow & \\ \frac{X - \frac{n}{2}}{\frac{\sqrt{n}}{2}} < -z_{\frac{\alpha}{2}} & \text{eller} & \frac{X - \frac{n}{2}}{\frac{\sqrt{n}}{2}} > z_{\frac{\alpha}{2}} \end{array}$$

Innsatt tall:

Observert verdi av testobservator:

$$Z = \frac{2562 - \frac{5000}{2}}{\frac{\sqrt{5000}}{2}} = 1.75$$

$\alpha = 0.10$  gir  $z_{\frac{\alpha}{2}} = 1.645$

Dvs. forkaster  $H_0$  og erklærer G som vinner av valget.

### Oppgave 3

a) La  $u_i = x_i(1 - x_i)$ ,  $i = 1, \dots, n$ . Modellen for avviket  $Y_i$  blir da

$$Y_i = au_i + \epsilon_i, \quad i = 1, \dots, n.$$

Likelihood-funksjonen er sannsynlighetstettheten til  $y_1, \dots, y_n$  gitt  $x_1, \dots, x_n$  med parameter  $a$ , som blir

$$\begin{aligned} L(a) &= f(y_1, \dots, y_n | x_1, \dots, x_n, a) = f(y_1 | x_1, a) \cdots f(y_n | x_n, a) \\ &= \prod_{i=1}^n f(y_i | x_i, a) = \prod_{i=1}^n n(y_i; au_i, \sigma_0^2) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} e^{-\frac{1}{2\sigma_0^2}(y_i - au_i)^2}. \end{aligned}$$

Videre blir log-likelihoodet

$$\begin{aligned} \ell(a) &= \log L(a) = \sum_{i=1}^n \left\{ -\frac{1}{2} \log(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} (y_i - au_i)^2 \right\} \\ &= -\frac{n}{2} \log(2\pi\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum_{i=1}^n (y_i - au_i)^2. \end{aligned}$$

Derivasjon med hensyn på  $a$  gir

$$\begin{aligned} \frac{\partial \ell(a)}{\partial a} &= -\frac{1}{2\sigma_0^2} \sum_{i=1}^n 2(y_i - au_i)(-u_i) \\ &= \frac{1}{\sigma_0^2} \sum_{i=1}^n (y_i u_i - au_i^2) \\ &= \frac{1}{\sigma_0^2} \sum_{i=1}^n y_i u_i - \frac{a}{\sigma_0^2} \sum_{i=1}^n u_i^2. \end{aligned}$$

Verdien av  $a$  som maksimerer  $\ell(a)$ , og dermed også  $L(a)$ , finnes ved å sette den deriverte lik null, og løse for  $a$ ,

$$\begin{aligned}\frac{\partial \ell(a)}{\partial a} &= 0 \\ \frac{a}{\sigma_0^2} \sum_{i=1}^n u_i^2 &= \frac{1}{\sigma_0^2} \sum_{i=1}^n y_i u_i \\ a &= \frac{\sum_{i=1}^n y_i u_i}{\sum_{i=1}^n u_i^2} = \frac{\sum_{i=1}^n x_i(1-x_i)y_i}{\sum_{i=1}^n (x_i(1-x_i))^2}.\end{aligned}$$

Det følger at sannsynlighetsmaksimeringsestimatoren for  $a$  er

$$\hat{a} = \frac{\sum_{i=1}^n x_i(1-x_i)Y_i}{\sum_{i=1}^n (x_i(1-x_i))^2}.$$

b) Forventningsverdien til estimatoren er

$$\begin{aligned}E(\hat{a}) &= E\left(\frac{\sum_{i=1}^n u_i Y_i}{\sum_{i=1}^n u_i^2}\right) \\ &= \frac{\sum_{i=1}^n u_i E(Y_i)}{\sum_{i=1}^n u_i^2} \\ &= \frac{\sum_{i=1}^n u_i \cdot a u_i}{\sum_{i=1}^n u_i^2} \\ &= a \frac{\sum_{i=1}^n u_i^2}{\sum_{i=1}^n u_i^2} = a,\end{aligned}$$

og variansen er

$$\begin{aligned}\text{Var}(\hat{a}) &= \text{Var}\left(\frac{\sum_{i=1}^n y_i u_i}{\sum_{i=1}^n u_i^2}\right) \\ &= \frac{1}{\left(\sum_{i=1}^n u_i^2\right)^2} \sum_{i=1}^n u_i^2 \text{Var}(Y_i) \\ &= \frac{\sum_{i=1}^n u_i^2 \sigma_0^2}{\left(\sum_{i=1}^n u_i^2\right)^2} \\ &= \frac{\sigma_0^2}{\sum_{i=1}^n u_i^2}\end{aligned}$$

Siden observasjonene  $Y_i$ ,  $i = 1, \dots, n$  er normalfordelte, og estimatoren  $\hat{a}$  er en lineærkombinasjon av  $Y_1, \dots, Y_n$ , vet vi at  $\hat{a}$  vil være normalfordelt med forventningsverdi  $E(\hat{a})$  og varians  $\text{Var}(\hat{a})$  som over,

$$\hat{a} \sim N\left(a, \sigma_0^2 / \sum_{i=1}^n u_i^2\right).$$

c) Siden  $a$  vil være lik null for en ideell blanding, og avvike fra null for en ikke-ideell blanding, kan følgende hypoteser brukes:

$$H_0 : a = 0, \quad H_1 : a \neq 0.$$

Under nullhypotesen har vi

$$\hat{a} \sim N(0, \text{Var}(\hat{a})),$$

slik at observatoren

$$Z = \frac{\hat{a}}{\sqrt{\text{Var}(\hat{a})}}$$

er standard normalfordelt. Vi forkaster  $H_0$  på signifikansnivå  $\alpha$  dersom  $|Z| > z_{\alpha/2}$ , som er ekvivalent med at  $|\hat{a}| > z_{\alpha/2} \sqrt{\text{Var}(\hat{a})}$ . Med  $\alpha = 5\%$  får vi  $z_{\alpha/2} = 1.96$ . Variansen  $\sigma_0^2 = 0.025^2$  og kvadratsummene  $\sum_{i=1}^n u_i y_i = -0.0945$  og  $\sum_{i=1}^n u_i^2 = 0.3333$  er gitt i oppgaveteksten. Ved å sette inn disse tallverdiene finner vi estimatet

$$\hat{a} = \frac{\sum_{i=1}^n u_i y_i}{\sum_{i=1}^n u_i^2} = \frac{-0.0945}{0.3333} = -0.2835,$$

og den kritiske verdien

$$z_{\alpha/2} \sqrt{\text{Var}(\hat{a})} = z_{0.025} \sqrt{\frac{\sigma_0^2}{\sum_{i=1}^n u_i^2}} = 1.96 \frac{0.025}{\sqrt{0.3333}} = 0.0849.$$

Det at  $\hat{a} < -z_{\alpha/2} \sqrt{\text{Var}(\hat{a})}$  betyr at  $|Z| > z_{\alpha/2}$ , så vi forkaster  $H_0$  på signifikansnivå  $\alpha = 5\%$ . Det er med andre ord grunnlag for å hevde at blandingen ikke er ideell.

d) Stigningstallet til tangentlinja er

$$\frac{E(Y|x) - z(x)}{x - 0} = \frac{ax(1-x) - z(x)}{x}.$$

Dette skal være lik den deriverte til  $E(Y|x) = ax(1-x)$ , som er

$$\frac{\partial}{\partial x} ax(1-x) = a(1-2x).$$

Ved å sette uttrykkene lik hverandre, får vi

$$\begin{aligned} \frac{ax(1-x) - z(x)}{x} &= a(1-2x) \\ ax(1-x) - z(x) &= ax(1-2x) \\ z(x) &= ax(1-x) - ax(1-2x) = ax^2. \end{aligned}$$

En rimelig estimator for  $z(x)$  er dermed  $\hat{z}(x) = \hat{a}x^2$ .

Et 95% konfidensintervall for  $a$  er

$$\hat{a} \pm z_{0.025} \sqrt{\text{Var}(\hat{a})} = \hat{a} \pm 1.96 \frac{\sigma_0}{\sqrt{\sum_{i=1}^n u_i^2}}.$$

Et tilsvarende 95% konfidensintervall for  $z(x_0) = ax_0^2$  er

$$\hat{a}x_0^2 \pm z_{0.025} \sqrt{\text{Var}(\hat{a}x_0^2)} = \hat{a}x_0^2 \pm 1.96 \sqrt{\frac{\sigma_0^2 \cdot (x_0^2)^2}{\sum_{i=1}^n u_i^2}} = \hat{a}x_0^2 \pm 1.96 \frac{\sigma_0 \cdot x_0^2}{\sqrt{\sum_{i=1}^n u_i^2}}.$$

Grensene til konfidensintervallet for  $z(x_0)$  er altså lik grensene for intervallet for  $a$ , multiplisert med  $x_0^2$ .

Med  $x_0 = 2/3$  blir konfidensintervallet for  $a$

$$(-0.3684, -0.1987),$$

mens konfidensintervallet for  $z(x_0)$  blir

$$(-0.3684 \cdot (2/3)^2, -0.1987 \cdot (2/3)^2) \quad \text{eller} \quad (-0.1637, -0.0883).$$